



Le cours ouvert de l'UVA sur la **RI** :

Introduction à la

Recherche d'Information

*Dr Kiswendsida Kisito Kaboré ,
Enseignant Chercheur Au
Département d'informatique
à l'UFR-SEA / UO 1 Pr JKZ*

Mai 2018

<http://kisitokab.xyz>

- **Prérequis**
 - Principes des systèmes de base de données
- **Volume horaire**
 - 60 heures
- **Méthode d'évaluation**
 - n Devoirs
 - 1 Projet

Justification du Cours/ module

- Les communications électroniques ou numériques ont enregistré un important développement du fait de la rapide croissance de l'Internet.
- Il a été constaté l'existence de différents modes de communications textuelles.
- Ces modes de communication ont un profond impact sur les organisations.
- Cependant, les importants volumes d'information générés dans les communautés en ligne posent problème en termes de facilité de la navigation, de gestion et de découverte de connaissances.

- En conséquence, le recours à des techniques susceptibles de renforcer l'efficacité des systèmes d'informations textuelles est une grande nécessité.
- Ainsi, il est impératif que les étudiants se familiarisent avec les techniques de base et avancées relatives aux systèmes d'information textuelle.

- Comprendre les notions fondamentales **et les concepts** de la recherche d'information .
- Avoir une meilleure connaissance et compréhension des techniques **de représentation textuelle, l'indexation, l'extraction**, d'analyses textuelles et la structure interne des moteurs de recherche ainsi que des algorithmes de recherche documentaire.
- ✓ être capable d'appliquer les connaissances et aptitudes acquises en matière de techniques de recherche documentaire.

Contenu-sujets du Cours

- Introduction à la RI:
 - notions fondamentales et les concepts
 - problématique
 - historique
- Représentation de documents et Indexation
- Modèles de RI
- Traitement des requêtes et Évaluation de la RI
- Moteurs de recherche sur le Web

- Avez-vous déjà
 - créé une base de données?
 - créé un schéma relationnel?
 - manipulé SQL ?
 - écrit des requêtes SQL?
- Quelle expériences avez-vous sur la recherche d'information ?

1) Définition

- [SRI]: Système de Recherche d'information.
C'est un système qui permet de retrouver les documents **pertinents** à une **requête** d'utilisateur, à partir d'une base de **documents** volumineuse.
- Dans cette définition, il y a trois notions clés : documents, requête, pertinence.

1) Définition

- **Document:** Un document peut être un texte, un morceau de texte, une page Web, une image, une bande vidéo, etc.
- On appelle document toute unité qui peut constituer une réponse à une requête d'utilisateur.
- Dans ce cours, nous traitons seulement des **documents textuels**.



Chapitre 1 : Introduction à la RI :



1) Définition

- **Requête:** Une requête exprime le besoin d'information d'un utilisateur.
- Elle est en général de la forme suivante:
"Trouvez les documents qui ...".

1) Définition

- Pertinence:

- Le but de la RI est de trouver seulement les documents pertinents.
- La notion de pertinence est très complexe. On reviendra là-dessus plus en détail plus tard.
- **De façon générale,** dans document pertinent, l'utilisateur doit pouvoir trouver les informations dont il a besoin. C'est sur cette notion de pertinence que le système doit juger si un document doit être donné à l'utilisateur comme réponse.

Chapitre 1 : Introduction à la RI :

- **Pertinence:**
- Même pour des documents textuels, il existe beaucoup de formes quant à leur spécification.
- Un document peut être un texte sans aucune structuration à l'intérieur (on l'appelle aussi plein-texte); il peut aussi être un texte avec une partie structurée, ou complètement structuré.
- Dans la plupart de cas, on traite des documents partiellement structurés: Par exemple, la spécification d'un livre peut être comme suit:

Chapitre 1 : Introduction à la RI :

- Par exemple, la spécification d'un livre peut être comme suit:
 - ISBN: 0-201-12227-8
 - Auteur: Salton, Gerard
 - Titre: Automatic text processing: the transformation, analysis, and retrieval of information by computer
 - Editeur: Addison-Wesley
 - Date: 1989
 - ...
 - Contenu: <Texte du livre>

Chapitre 1 : Introduction à la RI :

- Dans cette spécification,
 - une partie a été structurée (de ISBN à Date).
 - Une autre partie (Contenu) ne l'est pas.
- Il est possible de
 1. cherche ce livre par les attributs externes comme ISBN, Auteur, ..., Date.
 2. On peut aussi chercher ce livre par le contenu.

Chapitre 1 : Introduction à la RI :

- Le premier type de recherche est relativement simple, étant donné la structuration existante, et le critère relativement simple pour comparer la requête avec la spécification.
- Par contre, la recherche par le contenu pose beaucoup de problème :
 - ***C'est précisément cette dernière recherche qui est l'objet des études sur la RI*** (bien que la recherche via les attributs externes est aussi intégrée dans le même système).

1.2) Approches possibles



Chapitre 1 : Introduction à la RI :



2) Approches possibles

- On peut imaginer quelques approches possibles pour réaliser un système de RI.

1.2) *Approches possibles*

- **Une première approche très naïve** consiste à
 - considérer une requête comme une chaîne de caractères,
 - et un document pertinent comme celui qui contient cette chaîne de caractères.

1.2) Approches possibles

- À partir de cette vision simpliste, on peut imaginer l'approche qui consiste à balayer les documents séquentiellement, en les comparants avec la chaîne de caractères qui est la requête. Si on trouve la même chaîne de caractères dans un document, alors il est sélectionné comme réponse.

1.2) Approches possibles

- Cette approche est évidemment très simple à réaliser. Cependant, elle a plusieurs lacunes:
 1. **Vitesse**: L'opération de recherche est très **lente**. Pour chaque requête, on doit parcourir tous les documents dans la base. En général, il y en a des centaines de milliers, voire des millions. Il n'est donc envisageable d'utiliser cette approche que sur des collections très petites jusqu'à quelques centaines de documents.

1.2) Approches possibles

- Cette approche est évidemment très simple à réaliser. Cependant, elle a plusieurs lacunes:

1. Vitesse:

- ### 2. Pouvoir d'expression d'une requête:
- Une requête étant une simple chaîne de caractères, il est difficile d'exprimer des besoins complexes comme "Trouver des documents concernant la base de données et l'intelligence artificielle utilisées dans l'industrie".

1.2) Approches possibles

- Cette approche est évidemment très simple à réaliser. Cependant, elle a plusieurs lacunes:

1. Vitesse:

2. Pouvoir d'expression d'une requête:

- Ainsi, cette approche n'est utilisée que dans des systèmes jouets très petits. La plupart de systèmes existants utilisent une approche différente basée sur une indexation.

1.2) Approches possibles

- L'approche basée sur une indexation
- Dans cette approche, on effectue certains pré-traitements sur les documents et les requêtes, ce qu'on appelle l'indexation.

1.2) Approches possibles

- Cette opération d'indexation vise à construire une structure d'index qui permet à retrouver très rapidement les documents incluant des mots demandés. La structure d'index est de la forme suivante (la structure de fichier inversé):

Mot → {..., Doc, ...}

- C'est-à-dire, chaque mot est mis en correspondance avec les documents qui le contiennent.

1.2) Approches possibles

- Une requête peut être maintenant une expression plus complexe, incluant des opérateurs logiques (ET, OU, ...) ou d'autres types d'opérateurs.
- L'évaluation est compositionnelle, c'est-à-dire, on commence par évaluer les éléments de base (par exemple, des mots) dans la requête, obtenant ainsi des listes de documents; ensuite, on combine ces listes selon l'opérateur qui relie ces éléments pour obtenir finalement une seule liste de documents.

1.2) Approches possibles

- Par rapport à l'approche précédente, cette approche a les avantages suivants:
 1. Elle est plus rapide. En effet, on n'a plus besoin du parcours séquentiel. Avec la structure d'index, on peut directement savoir quels documents contiennent tel ou tel mot.
 2. L'expression des requêtes peut être très complexe, exprimant des besoins d'information complexes.

1.2) Approches possibles

- Le prix à payer pour ces avantages est :
 - le besoin de l'espace de stockage supplémentaire pour la structure d'index.
- En général, cet espace correspond **à 40% à 200%** de la taille de collection de documents, selon la complexité de l'indexation.
- Mais ce besoin d'espace pose de moins en moins de problème maintenant.

1.3) Notion de pertinence



1.3) Notion de pertinence



- Pertinence est la notion centrale dans la RI car toutes les évaluations s'articulent autour de cette notion.
- Mais c'est aussi la notion la plus mal connue, malgré de nombreuses études portant sur cette notion.
- Nous donnons dans ce qui suit, quelques définitions de la pertinence pour avoir une idée de la divergence.

1.3) Notion de pertinence

- La pertinence est:
 - la correspondance entre un document et une requête, une mesure d'informativité du document à la requête;
 - un degré de relation (chevauchement, relativité, ...) entre le document et la requête;
 - un degré de la surprise qu'apporte un document, qui a un rapport avec le besoin de l'utilisateur;
 - une mesure d'utilité du document pour l'utilisateur;
 - ...

1.3) Notion de pertinence

- Même dans ces définitions, les notions utilisées (informativité, relativité, surprise, ...) restent très vagues.
- Pourquoi on arrive à cette situation?
 - C'est parce que les utilisateurs d'un système de RI ont des besoins très variés.
 - Ils ont aussi des critères très différents pour juger si un document est pertinent.
- Donc, la notion de pertinence est utilisée pour recouvrir un très vaste éventail des critères et des relations.

1.3) Notion de pertinence

- Par exemple, un utilisateur qui a formulé la requête sur "système expert" peut être satisfait par un document décrivant toutes les techniques utilisées dans "MYCIN" qui est un exemple typique de système expert.
- Cependant, un deuxième utilisateur peut juger ce même document **non-pertinent** car il cherche plutôt une description non-technique.
- Dans les deux situations, on appelle **la relation entre le document et la requête** "**pertinence**".

1.3) Notion de pertinence

- Beaucoup de travaux ont été menés sur cette notion.
- On s'est vite aperçu que la pertinence n'est pas une relation isolée entre un document et une requête.
- Elle fait appel aussi au contexte de jugement.

1.4) Évaluation d'un système

1.4) Évaluation d'un système

- Le but de la RI est de trouver des documents pertinents à une requête, et donc utiles pour l'utilisateur.
- La qualité d'un système doit être mesurée en comparant les réponses du système avec les réponses idéales que l'utilisateur espère recevoir.
- Plus les réponses du système correspondent à celles que l'utilisateur espère, mieux est le système.

1.4) Évaluation d'un système

1.4.1. Corpus de test (références)

- Pour arriver à une telle évaluation, on doit connaître d'abord les réponses idéales de l'utilisateur.
- Ainsi, l'évaluation d'un système s'est faite souvent avec certains corpus de test.
- Dans un corpus de test, il y a:
 - un ensemble de documents;
 - un ensemble de requêtes;
 - la liste de documents pertinents pour chaque requête.

1.4) Évaluation d'un système

1.4.1. Corpus de test (références)

- Pour qu'un corpus de test soit significatif, il faut qu'il possède un nombre de documents assez élevé.
- Les premiers corpus de test développés dans les années 1970 renferment quelques milliers de documents.
- Les corpus de test plus récents (par exemple, ceux de TREC) contiennent en général plus 100 000 documents (considérés maintenant comme un corpus de taille moyenne), voir des millions de documents (corpus de grande taille).

1.4) Évaluation d'un système

1.4.1. Corpus de test (références)

- L'évaluation d'un système ne doit pas se reposer seulement sur une requête.
- Pour avoir une évaluation assez objective, un ensemble de quelques dizaines de requêtes, traitant des sujets variés, est nécessaire.
- L'évaluation du système doit tenir compte des réponses du système pour toutes ces requêtes.

1.4) Évaluation d'un système

1.4.1. Corpus de test (références)

- Finalement, il faut avoir les réponses idéales pour l'utilisateur pour chaque requête.
- Le dernier élément d'un corpus de test fournit cette information.

1.4) Évaluation d'un système

1.4.1. Corpus de test (références)

- Pour établir ces listes de documents pour toutes les requêtes, les utilisateurs (ou des testeurs simulant des utilisateurs) doit examiner chaque document de la base de document, et juger s'il est pertinent.
- Après cet exercice, on connaît exactement quels documents sont pertinents pour chaque requête.
- Pour la construction d'un corpus de test, les jugements de pertinence constituent la tâche la plus difficile.

1.4) Évaluation d'un système

1.4.1. Précision et rappel

- La comparaison des réponses d'un système pour une requête avec les réponses idéales nous permet d'évaluer les deux métriques suivantes:
- **Précision:** La précision mesure la proportion de documents pertinents retrouvés parmi tous les documents retrouvés par le système.
- **Rappel:** Le rappel mesure la proportion de documents pertinents retrouvés parmi tous les documents pertinents dans la base.

1.4) Évaluation d'un système

1.4.1. Précision et rappel

$$\text{Précision} = \frac{\text{Nombre de documents pertinents retrouvés}}{\text{Nombre de documents retrouvés}}$$

$$\text{Rappel} = \frac{\text{Nombre de document pertinents retrouvés}}{\text{Nombre de documents pertinents dans la base}}$$

1.4) Évaluation d'un système

1.4.1. Précision et rappel

- Idéalement, on voudrait qu'un système donne de bons taux de précision et de rappel en même temps. Un système qui aurait 100% pour la précision et pour le rappel signifie qu'il trouve tous les documents pertinents, et rien que les documents pertinents.

1.4) Évaluation d'un système

1.4.1. Précision et rappel

Cas où Précision=1 et rappel =1 :

- Cela veut dire que les réponses du système à chaque requête sont constituées de tous et seulement les documents idéaux que l'utilisateur a identifiés.
- En pratique, cette situation n'arrive pas.
- Plus souvent, on peut obtenir un taux de précision et de rappel aux alentours de 30%.

1.4) Évaluation d'un système

1.4.1. Précision et rappel

- Les deux métriques ne sont pas indépendantes.
 - Il y a une forte relation entre elles: quand l'une augmente, l'autre diminue.
 - Il ne signifie rien de parler de la qualité d'un système en utilisant seulement une des métriques.
 - En effet, il est facile d'avoir 100% de rappel: il suffirait de donner toute la base comme la réponse à chaque requête.
 - Cependant, la précision dans ce cas-ci serait très basse.
-
- Dr Kiswendsida Kisito Kaboré.*
<http://KisitoKob.kyz>
- De même, on peut augmenter la précision en donnant

1.4) Évaluation d'un système

1.4.1. Précision et rappel

- Les deux métriques ne sont pas indépendantes.
- Il y a une forte relation entre elles: quand l'une augmente, l'autre diminue.
- Il ne signifie rien de parler de la qualité d'un système en utilisant seulement une des métriques.
- En effet, il est facile d'avoir 100% de rappel: il suffirait de donner toute la base comme la réponse à chaque requête.
- *Cependant*, la précision dans ce cas-ci serait très basse.

1.4) Évaluation d'un système

1.4.1. Précision et rappel

- De même, on peut augmenter la précision en donnant très peu de documents en réponse, mais le rappel souffrira.
- Il faut donc utiliser les deux métriques ensemble.


1.4) Évaluation d'un système

1.4.1. Précision et rappel

- Les mesures de précision-rappel ne sont pas statiques non plus (c'est-à-dire qu'un système n'a pas qu'une mesure de précision et de rappel).
- Le comportement d'un système peut varier en faveur de précision ou en faveur de rappel (en détriment de l'autre métrique).
- Ainsi, pour un système, on a une courbe de précision-rappel qui a en général la forme suivante:

1.4) Évaluation d'un système

1.4.1. Précision et rappel



1.5) Bref historique de la RI

1.5) *Bref historique de la RI*

Les années 1940

- La RI n'est pas un domaine récent.
- Il date des années 1940, dès la naissance des ordinateurs.
- Au début, la RI se concentrait sur les applications dans des bibliothèques, d'où aussi le nom "automatisation de bibliothèques".
- Depuis le début de ces études, la notion de pertinence a toujours été un objet.



1.5) Bref historique de la RI



Les années 1940, 1950,

- Dans les années 1950, on commençait de petites expérimentations en utilisant des petites collections de documents (références bibliographiques).
- Le modèle utilisé est le modèle booléen.



1.5) Bref historique de la RI



Les années 1940, 1950, 1960-1970,

- Dans les années 1960 et 1970, des expérimentations plus larges ont été menées, et on a développé une méthodologie d'évaluation du système qui est aussi utilisée maintenant dans d'autres domaines.
- Des corpus de test (e.g. CACM) ont été conçus pour évaluer des systèmes différents.
- Ces corpus de test ont beaucoup contribué à l'avancement de la RI, car on pouvait les utiliser pour comparer différentes techniques, et de mesurer leurs impacts en pratique.

1.5) Bref historique de la RI

Les années 1940, 1950, 1960-1970,

- Le système qui a le plus influencé le domaine est sans aucun doute SMART, développé à la fin des années 1960 et au début des années 1970.
- Les travaux sur ce système a été dirigés par G. Salton, professeur à Cornell.

1.5) Bref historique de la RI

Les années 1940, 1950, 1960-1970,

- Certains nouvelles techniques ont été implantées et expérimentées pour la première fois dans ce système:
- par exemple
 - le modèle vectoriel
 - la technique de relevance feedback
- Du côté de modèle, il y a aussi beaucoup de développements sur le modèle probabiliste.



1.5) Bref historique de la RI



Les années 1940, 1950, 1960-1970, 1980

- Les années 1980 ont été influencées par le développement de l'intelligence artificielle.
- Ainsi, on tentait d'intégrer des techniques de l'IA en RI, par exemple, système expert pour la RI, etc.



1.5) Bref historique de la RI



Les années 1940, 1950, 1960-1970, 1980, 1990-1995-2018

- Les années 1990 (surtout à partir de 1995) sont des années de l'Internet.
- Cela a pour effet de propulser la RI en avant scène de beaucoup d'applications.
- C'est probablement grâce à cela que vous entendez parler de la RI.



1.5) Bref historique de la RI



Les années 1940, 1950, 1960-1970, 1980, 1990-1995-2018

- La venue de l'Internet a aussi modifié la RI : La problématique est élargie.
- Par exemple, on traite maintenant plus souvent des documents multimédia qu'avant.
- Cependant, les techniques de base utilisées dans les moteurs de recherche sur le web restent identiques.

1.6) Relations avec les Bases de Données

1.6) Relations avec les Bases de Données

- La RI a des relations fortes avec d'autres domaines, notamment avec les bases de données et avec des systèmes de question-réponse.
- On peut imaginer un système de RI comme un système de BD textuelles.

1.6) Relations avec les Bases de Données

- Cependant, il faut souligner la différence suivante entre les deux types de système:
- Dans une base de données, on doit d'abord créer des schémas pour organiser les données.
- Ces schémas définissent des relations, ainsi que les attributs dans chaque relation.
- C'est en utilisant ces schémas que le système arrive à interpréter une requête de l'utilisateur.

1.6) Relations avec les Bases de Données

- Par exemple, on peut définir la relation suivante dans une base de données:
- Auteur(Livre, Nom).
- où Auteur est le nom de la relation, Livre et Nom sont ses attributs qui correspondent à l'identification d'un livre et à son (un des) auteur(s). (Ceci est juste une partie de définition).

1.6) Relations avec les Bases de Données

- Pour trouver les livres écrits par "Knuth", on peut poser la requête suivante en SQL:
- **select** Livre
- **from** Auteur
- **where** Nom = "Knuth"
- Cette requête n'est valide que si la relation Auteur a été créée ainsi.

1.6) Relations avec les Bases de Données

- Dans la RI, une partie des spécifications de documents est structurée, notamment les attributs externes.
- Cette partie peut être organisée assez facilement comme une relation en BD, et ainsi utiliser des SGBD existants pour rechercher des documents selon des critères sur les attributs externes.

1.6) Relations avec les Bases de Données

- Mais, comme ce qu'on a dit, cette partie ne représente pas le cœur de la RI.
- Le cœur se situe dans la recherche selon le contenu.
- Or, le contenu est en général sans structure, ou avec une structure très souple.
- Il est très difficile de créer une relation pour représenter la partie contenu de document.

1.6) Relations avec les Bases de Données

- Après l'indexation de document, cependant, la connexion entre la RI et les BD devient plus étroite.
- Le résultat de l'indexation est d'associer à chaque document un ensemble d'index.
- Ce résultat peut être vu comme une relation en BD:

Index(Doc, Mot).

1.6) Relations avec les Bases de Données

Index(Doc, Mot).

- Ainsi, il est possible de faire une requête pour sélectionner les documents contenant le mot "recherche" et le mot "information" comme suit:
(**select** Doc **from** Index **where** Mot = "recherche")
intersect
(**select** Doc **from** Index **where** Mot = "information")
- ce qui signifie que l'intersection de deux sélections sera le résultat.

1.6) Relations avec les Bases de Données

- Noter, cependant, que les sélections ne retournent qu'un ensemble de documents sans ordonnancement.
- En RI, l'ordre de documents dans la liste de réponse est important. Ainsi, les BD ne permettent de réaliser qu'une partie de fonctionnalités de la RI.

