

Recherche d'Information(RI)

Traitement des Requêtes et évaluation de la RI.

*Dr Kiswendsida Kisito Kaboré ,
Enseignant Chercheur Au
Département d'informatique
à l'UFR-SEA / UO 1 Pr JKZ*

- Introduction à la RI:
 - notions fondamentales et les concepts
 - problématique
 - historique
- Représentation de documents et Indexation
- Modèles de RI
- **Traitement des requêtes et Évaluation de la RI**
- Moteurs de recherche sur le Web

Objectif

- À la fin de cette unité, vous devriez être capable de:
 - Maîtriser les techniques d'expansion.
 - Réaliser correctement des mesure pertinentes.
 - Réaliser correctement des évaluation.

Chapitre 4 : Traitement des requêtes et Évaluation de la RI

Introduction

- Nous expliquons dans ce chapitre, les différentes techniques
 - d’expansion des requêtes,
 - de mesure et
 - d’évaluation de RI

4.1) Expansion de requêtes

4.1) Expansion de requêtes

- **Introduction :**

- Dans la plupart des collections de documents, un concept donné peut être traduit par différents termes.
- Cette notion de synonymie entre termes affecte le *rappel* des moteurs de recherche.
- Ainsi, avec une requête qui contiendrait tous les synonymes d'un concept recherché, on peut espérer obtenir, en tête de liste, les documents portant sur les différentes facettes de ce concept.

4.1) Expansion de requêtes

- Introduction :

- Différentes techniques ont été proposées en RI pour mieux préciser les besoins d'information des utilisateurs, en affinant les requêtes associées à ces besoins.
- Une technique simple consiste bien sûr à utiliser des **dictionnaires de synonymes**, soit de langue générale (comme Wordnet) soit de langue de spécialité (ressources terminologiques ou ontologiques).
- Dans ce type d'approche, souvent qualifié **d'approche globale**, on ajoute à un terme de la requête **tous ses synonymes** dans les ressources à disposition, et on exécute ensuite la **requête enrichie**.

4.1) Expansion de requêtes

- Introduction :

- Cette technique, souvent couplée à un **correcteur orthographique** permettant de corriger les fautes de frappe, fonctionne très bien dès lors que l'on dispose de ressources adaptées au corpus, comme c'est le cas pour le domaine médical qui a connu un fort développement terminologique.

4.1) Expansion de requêtes

- Introduction :

- Toutefois, le développement de telles ressources est **coûteux**, et beaucoup de chercheurs et d'ingénieurs se sont intéressés à des techniques automatiques permettant d'extraire des termes reliés aux termes de la requête directement à partir de la collection.
- **Ce sont ces techniques d'expansion de requêtes** (on parle également **d'enrichissement de requêtes**), connues sous le nom de **retour de pertinence**, que nous présentons ici.
- Notons enfin que ce type d'approche est **qualifié de local**.

4.1) Expansion de requêtes

- **Introduction :**

- Les approches locales d'expansion enrichissent, pour la plupart, la représentation vectorielle des requêtes en s'appuyant sur un premier résultat de recherche entre la requête initiale et les documents de la collection.
- Les deux méthodes les plus connues suivant cette approche sont
 - la boucle de rétropertinence (*relevance feedback* en anglais) et
 - la boucle de rétropertinence en aveugle (*pseudo relevance feedback* en anglais)

4.1.1) La méthode « boucle de rétropertinence »

- 4.1.1 La méthode « boucle de rétropertinence »
 - Cette méthode implique l'utilisateur dans le processus de recherche, dans le sens où
 - ce dernier fournit un retour sur la pertinence des documents renvoyés lors d'un premier appariement entre la requête et les documents d'une collection.

4.1.1) La méthode « boucle de rétropertinence »

• 4.1.1 La méthode « boucle de rétropertinence »

- Cette procédure est illustrée dans la figure 3.4, dans laquelle
 - (a) un utilisateur exprime un besoin d'information initial qui est formulé sous forme d'une requête ;
 - (b) le système de recherche renvoie alors un premier ensemble de documents, triés dans l'ordre décroissant du score entre la requête initiale et ces derniers (voir section 3.1) ;

4.1.1) La méthode « boucle de rétropertinence »

• 4.1.1 La méthode « boucle de rétropertinence »

- (c) l'utilisateur marque alors quelques documents de cette liste comme pertinents ou non pertinents par rapport à la requête ;
 - (d) le système enrichit alors la représentation vectorielle de la requête en tenant compte de ce retour, et un nouveau résultat de recherche est fourni à l'utilisateur sur la base de la requête modifiée.
- Les étapes (c) et (d) sont souvent répétées, et ce jusqu'à ce que l'utilisateur soit satisfait des résultats finaux ou qu'il arrête le processus.

4.1.1) La méthode « boucle de rétropertinence »

- 4.1.1 La méthode « boucle de rétropertinence »
 - L'idée principale sous-jacente à cette approche est qu'il est difficile de formuler une requête précise car l'ensemble des informations contenues dans une collection donnée n'est en général pas connu à l'avance.
 - En revanche, la requête exacte peut cependant être approchée en enrichissant la représentation vectorielle de la requête initiale avec des documents marqués comme pertinents et non pertinents par l'utilisateur.
 - La méthode associée la plus connue est celle de **Rocchio** qui, dans un premier temps, cherche, à partir des ensembles de documents jugés *pertinents*, D_p , et *non pertinents*,




Fig. 4.1– Boucle de rétopertinence sur la base de la figure 3.1

4.1.1) La méthode « boucle de rétropertinence »

- $\mathcal{D}_{np}$, la requête unitaire q^* qui maximise la différence de score entre les ensembles pertinents et non pertinents :

$$q^* = \operatorname{argmax}_q \left(s(q, \mathcal{D}_p) - s(q, \mathcal{D}_{np}) \right), \quad \text{avec } \|q^*\| = 1$$

- Dans le cas où la mesure de similarité utilisée est la fonction cosinus, on peut montrer que cette condition se traduit par la relation vectorielle suivante:

$$q^* \propto \frac{1}{\|\mathcal{D}_p\|} \sum_{d \in \mathcal{D}_p} d - \frac{1}{\|\mathcal{D}_{np}\|} \sum_{d' \in \mathcal{D}_{np}} d'$$

•

4.1.1) La méthode « boucle de rétropertinence »

- $\mathcal{D}_{np}$, la requête unitaire q^* qui maximise la différence de score entre les ensembles pertinents et non pertinents :
 - $q^* = \underset{q}{\operatorname{argmax}} \left(s(q, \mathcal{D}_p) - s(q, \mathcal{D}_{np}) \right), \text{ avec } \|q^*\| = 1$
 -
 - Dans le cas où la mesure de similarité utilisée est la fonction cosinus, on peut montrer que cette condition se traduit par la relation vectorielle suivante:
 -
 - $q^* \propto \frac{1}{\|\mathcal{D}_p\|} \sum_{d \in \mathcal{D}_p} d - \frac{1}{\|\mathcal{D}_{np}\|} \sum_{d' \in \mathcal{D}_{np}} d'$
 -
 -
 - où
- $$\|\mathcal{D}_p\| = \left\| \sum_{d \in \mathcal{D}_p} d \right\|$$
- (la relation pour $\|\mathcal{D}_{np}\|$ étant similaire) .

4.1.1) La méthode « boucle de rétropertinence »

- La formule de **Rocchio** consiste alors à enrichir la requête initiale q_0 avec les termes de la requête q^* , cet enrichissement étant contrôlé par des poids qui peuvent être réglés automatiquement (ou manuellement) sur de nouvelles collections :

$$q^{new} = \alpha q_0 + \beta \frac{1}{\|\mathcal{D}_p\|} \sum_{d \in \mathcal{D}_p} d - \gamma \frac{1}{\|\mathcal{D}_{np}\|} \sum_{d' \in \mathcal{D}_{np}} d'$$

avec α , β et γ des réels positifs ou nuls.

- .

4.1.1) La méthode « boucle de rétropertinence »

- En pratique, γ est souvent considéré comme nul, et l'on considère un seul poids contrôlant l'influence des nouveaux termes à ajouter la requête initiale q_0 :

$$q^{new} = q_0 + \beta \frac{1}{\|\mathcal{D}_p\|} \sum_{d \in \mathcal{D}_p} d$$

- β peut alors être obtenu en cherchant la valeur qui maximise la précision moyenne sur un ensemble de test.
- Il est maintenant bien établi que la boucle de rétropertinence permet d'améliorer le rappel et la précision d'un système de recherche.

4.1.2) La méthode « boucle de rétropertinence en aveugle »

- Cette méthode
 - dérive de la précédente et
 - permet d'éviter la phase d'annotation des documents pertinents en supposant que, pour une requête donnée,
 - les k premiers documents renvoyés par un moteur de recherche sont pertinents par rapport à cette dernière
 - (en pratique, k est souvent fixé à 5, 10 ou 20).

4.1.2) La méthode « boucle de rétropertinence en aveugle »

- Cette hypothèse
 - rend automatique l'approche précédente et
 - simplifie sa mise en place, puisque
 - les jugements de pertinence d'un utilisateur ne sont plus requis.

4.2) Mesures d'évaluation

4.2) Mesures d'évaluation

Introduction

- Pour mesurer l'efficacité d'un modèle de recherche nous avons besoin
 - d'une collection de documents test,
 - d'un ensemble de requêtes et
 - d'un ensemble de jugements de pertinence.
- Chaque jugement de pertinence
 - est généralement une évaluation binaire,
 - sous la forme pertinent ou non pertinent,
 - pour une paire constituée d'un document et d'une requête.

4.2) Mesures d'évaluation

Introduction

- Certains jugements prennent toutefois
 - la forme de score entre 0 et 5 par exemple,
 - 0 désignant un document non pertinent pour la requête, et
 - 5 un document parfaitement pertinent.
- Afin qu'une collection de test permette de comparer différentes approches, il est nécessaire qu'elle contienne un nombre **suffisant de requêtes** (avec jugements de pertinence).

4.2) Mesures d'évaluation

Introduction

- La limite inférieure de ce nombre est en général donnée à 25 ou 30, car c'est à partir de cette gamme que l'on peut utiliser des tests de **significativité statistique** comme le **test de Student** ou le **test de Wilcoxon**.
- Ces tests indiquent si la différence entre deux séries de résultats (et donc entre deux systèmes) est **significative** (c'est-à-dire si elle n'est pas le fruit du hasard).

4.2) Mesures d'évaluation

Introduction

- Il existe **plusieurs collections de test de référence**, en général développées dans le cadre de campagne d'évaluation dont les principales sont :
 - **La campagne TREC 15**, pour *Text REtrieval Conference*,
 - est certainement la plus connue de ces campagnes.
 - Elle existe depuis 1992 et
 - a permis le développement de collections de test sur divers aspects de la RI.
 - Il est possible de récupérer ces collections en s'adressant aux organisateurs et/ou en participant aux campagnes en cours (mais seules les collections de ces campagnes sont alors fournies).
 -

4.2) Mesures d'évaluation

Introduction

— La campagne CLEF,

- originellement *Cross-Language Evaluation Forum*,
- maintenant *Conference and Labs of the Evaluation Forum*,
- a été créée de façon à développer les systèmes de RI sur d'autres langues que l'anglais (qui était la langue principale de TREC).
- La recherche d'information multilingue a grandement bénéficié de cette campagne et des collections qui y furent développées.
- Tout comme TREC, CLEF regroupe maintenant plusieurs sous-tâches de la RI ainsi que des collections d'images.

4.2) Mesures d'évaluation

Introduction

— La campagne NTCIR,

- pour *NII Test Collection for IR*,
- est une initiative du *National Institute of Informatics* japonais.
- Cette campagne propose des tâches en RI *ad hoc* (en particulier sur des brevets),
- en question-réponse et en
- recherche d'information multilingue.

4.2) Mesures d'évaluation

Introduction

— La campagne INEX,

- pour *Initiative for the Evaluation of XML Retrieval*,
- qui s'intéresse plus particulièrement à des documents structurés.

— La campagne FIRE,

- pour *Forum for Information Retrieval Evaluation*,
- est une initiative plus récente,
- créée en 2008.
- L'accent est mis dans cette campagne sur les langues d'Asie du Sud.

4.2.1) Évaluation de résultats non ordonnés

- **4.2.1 Évaluation de résultats non ordonnés**
- Les deux mesures d'évaluation les plus utilisées en RI sont
 - le rappel et
 - la *précision*.
- Pour des résultats non ordonnés de recherche, le *rappel* est la fraction des documents pertinents par rapport à un besoin d'information retournés par le système :
- $$\text{Rappel} = \frac{\text{Nombre de document pertinents retrouvés}}{\text{Nombre de documents pertinents dans la base}}$$

4.2.1) Évaluation de résultats non ordonnés




Fig. 3.5 – Description schématique des mesures rappel et précision. Le sous-ensemble des documents pertinents par rapport à un besoin d'information est illustré par des hachures et l'ensemble des documents retournés par le système comme pertinents par rapport à ce même besoin d'information, est montré par des points.

4.2.1) Évaluation de résultats non ordonnés

- La précision est la fraction de documents pertinents dans les résultats retournés par le système :
- $$\text{Précision} = \frac{\text{Nombre de documents pertinents retrouvés}}{\text{Nombre de documents retrouvés}}$$

4.2.1) Évaluation de résultats non ordonnés

- Ces deux mesures peuvent être calculées pour
 - chaque requête, et
 - moyennées sur l'ensemble des requêtes.
- Il existe clairement un compromis entre ces deux mesures.
 - Sur la figure 3.5, nous voyons bien que le **rappel** d'un système qui **retourne l'ensemble des documents d'une collection** comme pertinents sera égal à 1, alors que la précision de ce système serait très faible.
 - En contrepartie, la **précision** d'un système qui **retourne avec succès très peu de documents**, tous pertinents, sera très grande par rapport à son rappel.

4.2.1) Évaluation de résultats non ordonnés

- Il existe des situations où l'on préfère un **système de forte précision** sans préférence particulière sur son rappel.
- C'est le cas par exemple d'un **moteur de recherche sur la Toile**,
 - où on aimerait que pour n'importe quelle requête,
 - tous les documents retournés en première page des résultats soient pertinents
 - sans pour autant chercher à connaître l'ensemble des documents pertinents associés aux requêtes.

4.2.1) Évaluation de résultats non ordonnés

- Dans d'autres situations, au contraire, comme la **recherche sur disque dur**, on préfère souvent des systèmes **qui retournent l'ensemble des documents pertinents** par rapport à une requête (donc avec un fort rappel) en tolérant des imprécisions sur les résultats de recherche.

4.2.1) Évaluation de résultats non ordonnés

- Finalement, dans les cas où l'on souhaite obtenir un système qui ne privilégie pas uniquement une des deux mesures, il est d'usage d'utiliser la **moyenne harmonique pondérée** entre le rappel et la précision (cette moyenne harmonique est plus connue sous le nom de **mesure-F**) :

4.2.1) Évaluation de résultats non ordonnés

- **mesure-F:**

$$F_{\beta} = (1 + \beta^2) \frac{\text{précision} \times \text{rappel}}{\beta^2 \times \text{précision} + \text{rappel}} = \frac{1}{\theta \frac{1}{\text{précision}} + (1 - \theta) \frac{1}{\text{rappel}}}$$

- Avec

$\theta = \frac{1}{(1+\beta^2)}$, $\beta \in R_+$ et $\theta \in [0,1]$. Des valeurs de $\beta > 1$ (respectivement $\beta < 1$)

- correspondent aux cas où le rappel prévaudrait sur la précision (respectivement la précision prévaudrait sur le rappel).
- Le cas où précision et rappel sont considérés d'égale importance correspond à $\beta = 1$ (ou $\theta = \frac{1}{2}$) et à la mesure usuelle F1 :
- $F_1 = \frac{2 \times \text{précision} \times \text{rappel}}{\text{précision} + \text{rappel}}$
-

- **4.2.2 Évaluation de résultats ordonnés**
- La **précision**, le **rappel** et la **mesure-F** sont des métriques qui se calculent sur une **liste globale et non ordonnée de documents retournés** par un système de recherche.
- Or les moteurs de recherche traditionnels produisent des **listes ordonnées** de documents dans lesquelles s'entremêlent **documents pertinents et non pertinents**, et la position des documents pertinents devient cruciale pour mesurer la qualité d'un système de RI.
- Dans la suite, nous allons présenter les mesures d'évaluations les plus usuelles en RI proposées pour des résultats ordonnés.

- La courbe précision-rappel
- Cette courbe s'obtient
 - en calculant des valeurs de rappel et de précision
 - sur des sous-ensembles de documents,
 - de taille croissante,
 - déduits à partir d'une liste de documents ordonnés.
- L'ensemble des mesures de rappel et de précision ainsi obtenues permet alors de tracer la courbe de la **précision, $P(r)$, en fonction du rappel r .**

- La courbe précision-rappel
- Considérons l'exemple jouet suivant, dans lequel
- **10 documents** sont **ordonnés** par rapport à la réponse d'un modèle de recherche **M**,
- **estimant** la similarité ou la probabilité de pertinence ou de génération de ces documents par rapport à une **requête q** donnée.

Example

rg	Réponse de $\mathcal{M}$	$R_{d_{rg},q}$	rappel, r	précision, $P(r)$
1	0,95	1	1/4	1
2	0,82	0	1/4	1/2
3	0,75	0	1/4	1/3
4	0,7	1	1/2	1/2
5	0,65	1	3/4	3/5
6	0,5	0	3/4	1/2
7	0,4	0	3/4	3/7
8	0,35	1	1	1/2
9	0,2	0	1	4/9
10	0,1	0	1	2/5

Tab. 3.2 – Mesures de rappel et de précision sur un ensemble de 10 documents ordonnés d’après la réponse d’un moteur de recherche M pour une requête fictive q . $R_{drg,q}$ correspond à la valeur du jugement de pertinence associé au document d situé au rang rg de la liste ordonnée, par rapport à la requête q

- Supposons qu'il y a aussi dans cet ensemble, **4 documents jugés pertinents** pour cette requête.
- Le tableau 3.2 donne les **mesures de précision et de rappel** pour chaque document ordonné dans cette liste et
- la figure 3.6 donne la **courbe précision-rappel** correspondante.




Fig. 3.6 – Courbes précision-rappel (en pointillé) et précision interpolée (en trait plein) obtenues à partir de l'exemple du tableau 3.2.

- Cette courbe est en dents de scie : à un rang rg donné sur la liste des documents ordonnés,
 - si le document de rang ($rg + 1$) est non pertinent, le rappel au rang $rg + 1$ restera le même que le rappel du système pour les rg premiers documents alors que la précision sera diminuée.
 - Au contraire, si le document de rang ($rg + 1$) est pertinent, alors rappel et de précision **croissent**.
 - Il est souvent de mise d'enlever ces oscillations en lissant la courbe de précision-rappel avec une technique qui consiste à estimer une valeur de précision définie pour chaque valeur de rappel $\rho \in [0,1]$ par :

$$\forall \rho \in [0,1] \theta, \prod(\rho) = \max\{P(r) \mid r \geq \rho\}$$

4.2.2) Évaluation de résultats ordonnés

- Cette mesure, plus connue sous le nom de **précision interpolée**, est montrée en trait plein sur la figure 3.6.
- La fonction $\Pi(\rho)$ peut être interprétée comme le pourcentage de documents pertinents qu'un utilisateur observera s'il veut atteindre un taux de rappel au moins égal à $\Pi(\rho)$
- En pratique, les courbes de précision-rappel sont obtenues en calculant la précision interpolée $\Pi(\rho)$ pour les 11 valeurs de ρ (0 ; 0,1 ; ... ; 1,0).

- Pour les cas où il est plus important d'évaluer la performance d'un système pour une requête q sur les premiers documents retournés (c'est-à-dire sur les documents de rang faible),
- une mesure alternative à ces courbes est la **précision moyenne à un rang k** donné, **$P@k(q)$** , définie comme :

$$P@k(q) = \frac{1}{k} \sum_{rg=1}^k R_{d_{rg},q}$$

- où $R_{d_{rg},q} \in [0,1]$ est le jugement de pertinence du document de rang rg dans la liste retournée par le système pour la requête q .
- Dans les compétitions internationales en RI, les valeurs de k usuelles sont prises dans l'ensemble $[5, 10, 15, 20]$.

- La précision moyenne
- La précision moyenne (*Average Precision* en anglais)
 - d'un système de recherche M pour une requête q donnée,
 - notée souvent **AveP**,
 - est la moyenne des valeurs de précision des documents pertinents
 - par rapport à q
 - dans la liste ordonnée des réponses :
- $$AveP(q) = \frac{1}{n_+^q} \sum_{k=1}^N R_{d_{rg}q} \times P@k(q)$$
- où $n_+^q = \sum_{i=1}^N R_{d_{iq}}$ est le nombre total de documents pertinents par rapport à q .

- **La précision moyenne**
- Pour simplifier les calculs, la **précision interpolée** est parfois utilisée pour calculer cette moyenne.
- Dans notre exemple, on a :
- $$AveP(q) = \frac{1}{11} \sum_{\rho \in [0;0,1;...;1,0]} \Pi(\rho)$$
- **On peut remarquer**, au travers de cette définition, que la précision moyenne ($AveP$) est une approximation de **l'aire sous la courbe de la précision interpolé**.

- **La précision moyenne**
- Dans les cas où, on dispose d'un ensemble de requêtes
- $Q = [q_1, \dots, q_{|Q|}]$,
- on peut étendre l'évaluation précédente en calculant la **moyenne des précisions moyennes**
- (communément appelée **MAP** pour *Mean Average Precision* en anglais)
- sur l'ensemble de ces requêtes :
- $$MAP = \frac{1}{|Q|} \sum_{j=1}^{|Q|} AveP(q_j) = \frac{1}{|Q|} \sum_{j=1}^{|Q|} \frac{1}{n_+^{q_j}} \sum_{k=1}^N R_{d_k q_j} \times P@k(q_j)$$
- Dans les différentes campagnes d'évaluation, la mesure *MAP* est largement employée pour sa capacité discriminatoire et sa stabilité.

- **La courbe ROC**
- La courbe ROC
 - (*Receiver Operating Characteristics* en anglais)
 - indique la capacité d'un système de recherche à
 - ordonner les documents pertinents par rapport à une requête q
 - avant les documents non pertinents.
- En partant d'une liste ordonnée de documents,
 - cette courbe se construit en
 - estimant le taux de documents pertinents (ou le rappel)
 - à chaque rang rg sur cette liste (r_{rg}),
 - en fonction du taux de documents non pertinents ordonnés avant ce rang (τ_{rg}).
- Le tableau suivant montre, la courbe *ROC* correspondant à l'exemple jouet précédent.

4.2.2) Évaluation de résultats ordonnés

rg	$R_{d_{\tau, q}}$	τ_{rg}	r_{rg}
1	1	0	1/4
2	0	1/6	1/4
3	0	1/3	1/4
4	1	1/3	1/2
5	1	1/3	3/4
6	0	1/2	3/4
7	0	2/3	3/4
8	1	2/3	1
9	0	5/6	1
10	0	1	1




Tableau 5 – Différentes paires de valeurs (τ_{rg} , r_{rg}) calculées pour l'exemple jouet du tableau 4, où τ_{rg} est le taux de documents non pertinents ordonnés avant le rang rg , et r_{rg} est le *rappel* au rang rg (gauche) ainsi que la courbe ROC correspondante (droite).

- La définition de la courbe *ROC* a été proposée en dehors du cadre de la RI et elle est largement utilisée dans beaucoup de domaines comme
 - la médecine,
 - la biométrie,
 - l'apprentissage machine

- D'une façon générale, **l'aire sous la courbe ROC** est un indicateur de la capacité d'un **système M** à ordonner les documents pertinents au-dessus des documents non pertinents par rapport à une requête q et elle peut être définie comme :

$$AUC(M, q) = \frac{1}{n_+^q n_-^q} \sum_{i: R_{d_i q} = 1} \sum_{j: R_{d_j q} = 0} \left(\mathbb{1}_{rg(d_i) < rg(d_j)} + \frac{1}{2} \mathbb{1}_{rg(d_i) = rg(d_j)} \right)$$

- où $nq+$ (respectivement $nq-$) est le nombre de documents pertinents (respectivement non pertinents) par rapport à q , $rg(d)$ désigne le rang du document d dans la liste ordonnée des documents par M et 1_π est la fonction indicatrice qui est égale à 1 si le prédicat π est vrai et 0 sinon..

4.2.2) Évaluation de résultats ordonnés

- Pour simplifier les calculs, il est souvent de mise d'utiliser la mesure complémentaire $1 - AUC$ définie comme :
- $$1 - AUC(M, q) = \frac{1}{n_+^q n_-^q} \sum_{i: R_{d_i q} = 1} \sum_{j: R_{d_j q} = 0} \left(\mathbb{1}_{rg(d_i) \geq rg(d_j)} \right)$$
- Pour l'exemple jouet précédent, on trouve $AUC(M, q) = 23$.

- Le gain cumulatif réduit
- Le gain cumulatif réduit
 - noté usuellement par *DCG* pour *Discounted Cumulative Gain*
 - mesure l'efficacité d'un système de recherche
 - dans le cas où les jugements de pertinence sur les documents ne sont plus binaires mais prennent des valeurs dans un sous-ensemble de valeurs discrètes de N .

- Le gain cumulatif réduit
- En fait, adopter des jugements de pertinence binaires revient à faire l'hypothèse que tous les documents pertinents le sont également.
- Ceci est bien sûr faux car certains documents, ciblant mieux les thématiques exprimées dans la requête, sont de meilleures réponses que les documents dont seul un passage est pertinent.

- **Le gain cumulatif réduit**

- Il est donc souvent souhaitable (mais malheureusement pas toujours réalisable en pratique) d'adopter une échelle de pertinence allant par exemple de 0 à 5 : 0 pour les documents non pertinents, 5 pour les documents parfaits, les degrés intermédiaires servant à caractériser des documents plus ou moins pertinents.
- Le gain cumulatif réduit évalue l'utilité, ou le gain, d'un document en fonction de son score de pertinence.
- Cette utilité est additionnée pour chaque document depuis la tête de la liste de documents retournés, et ce jusqu'à la position souhaitée.

- Le gain cumulatif réduit
- Toutefois, dans la mesure où obtenir l'ensemble des documents pertinents en tête de liste est plus intéressant que de les trouver en queue de liste, le gain est pondéré par la position à laquelle chaque document apparaît
- (c'est en fait le $\log_2$ de la position qui est utilisé de façon à ne pas trop donner d'importance à ce facteur).

- Le gain cumulatif réduit
- (c'est en fait le log2 de la position qui est utilisé de façon à ne pas trop donner d'importance à ce facteur).
- Comme pour la précision en tête de liste, $P@k$,
 - la mesure **DCG** pour une requête q donnée est évaluée à un rang k
 - (k prend en général les mêmes valeurs que pour la précision en tête de liste : 5, 10, 20 ou 25).

$$DCG@k(q) = \sum_{rg=1}^k \frac{2^{R_{drgq}} - 1}{\log_2(1 + rg)}$$

- Le gain cumulatif réduit

$$DCG@k(q) = \sum_{rg=1}^k \frac{2^{R_{drgq}} - 1}{\log_2(1 + rg)}$$

- En pratique, il est de mise de **normaliser** la mesure précédente en la multipliant par un facteur normalisateur adéquat afin d'obtenir un gain égal à 1.
- Ceci est réalisé en divisant le gain cumulatif réduit par celui obtenu avec un système idéal, parfait, qui placerait en tête de liste les documents les plus pertinents, de score 5 par exemple, puis les documents de score 4,... et enfin les documents de score 0.

<http://www.iro.umontreal.ca/~nie/IFT6255/>

