



Le cours ouvert de l'UVA sur la RI :

Recherche d'Information

Chapitre 5 :

Les Moteurs de recherche sur le web.

*Dr Kiswendsida Kisito Kaboré ,
Enseignant Chercheur Au
Département d'informatique
à l'UFR-SEA / UO 1 Pr JKZ*

Mai 2018

<http://kisitokab.xyz>



Contenu-sujets du Cours

- Introduction à la RI:
 - notions fondamentales et les concepts
 - problématique
 - historique
- Représentation de documents et Indexation
- Modèles de RI
- Traitement des requêtes et Évaluation de la RI
- **Moteurs de recherche sur le Web**

Objectif

- À la fin de cette unité, vous devriez être capable de:
 - comprendre et de maîtriser l'application de la RI sur Web à travers la présentation de quelques exemples

5.1) Introduction

Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- Il y a des situation problématique liés au développement de la Toile, dont les deux principaux sont :
 - (a) la création, la modification et la suppression spontanées d'informations sans aucune coordination au préalable et



Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- (b) le grand nombre de données existantes, font que la recherche sur le Web est différente de la recherche traditionnelle présentée dans les chapitres précédents.

Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- L'évolution du Web est principalement due à trois inventions centrales :
 - 1. le format standardisé pour représenter les données avec le langage de balisage HTML (Hypertext Markup Language, en anglais) ;

Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- 2. le protocole de communication client-serveur pour le transfert hypertexte, HTTP (HyperText Transfer Protocol, en anglais) ;



Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- 3. les adresses Web qui sont à la base des liens hypertextes et qui permettent d'identifier les données sur la Toile.

Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- Ces inventions ont permis le développement de nouvelles technologies à deux niveaux distincts :
 - collecte et indexation des données, et
 - conception de nouvelles stratégies qui permettent d'améliorer l'efficacité de la recherche.
- Ces technologies sont en évolution et innovation permanentes(, et sans rechercher l'exhaustivité, nous n'allons présenter que celles qui sont les plus abouties).



Chapitre 5 : Les Moteurs de recherche sur le web.

5.1) Introduction

- La suite de ce chapitre est structurée de la façon suivante ;
 - l'architecture de la Toile,
 - langage HTML, puis
 - le protocole HTTP et
 - les adresses Web.
- La collecte et l'indexation des pages sur la Toile sont ensuite abordées et enfin, nous exposons trois stratégies qui ont été conçues pour prendre en compte les nouvelles spécificités entrant en jeu dans la création des pages Web et permettant d'améliorer grandement les résultats de recherche.

5.2) Architecture de la Toile

5.2) Architecture de la Toile

- L'architecture de la Toile repose sur deux éléments fondamentaux, appelés,
 - d'une part, interaction et recherche, et
 - d'autre part, collecte et indexation comme montré dans la figure qui suit.



Figure 15 – Différentes étapes de la recherche sur la Toile avec les deux éléments (a) de collecte et d'indexation, et (b) d'interaction et de recherche, séparés par des pointillés.

5.2) Architecture de la Toile

- En amont de toute recherche, **un robot d'indexation** (web crawler ou spider en anglais)
 - récupère les pages de la Toile suivant différentes stratégies, et
 - les transfère à un sous-système d'indexation qui
 - les analyse et les stocke dans les fichiers d'index.

5.2) Architecture de la Toile

- **Dans la phase de recherche,**
- un utilisateur
 - exprime son besoin d'information
 - via l'interface d'un navigateur, qui
 - est généralement constituée d'une page Web avec une zone de saisie.

5.2) Architecture de la Toile

- Le navigateur
 - analyse ensuite la demande dans une forme que son moteur de recherche associé peut comprendre et
 - lui envoie une requête.

5.2) Architecture de la Toile

- Le moteur de recherche
 - exécute l'opération de recherche sur les fichiers d'index construits dans la phase précédente et
 - trie les données jugées pertinentes par rapport à la demande initiale qui
 - sont au final montrées à l'utilisateur via une autre interface du navigateur.

5.3) Trois inventions à la base du Web

5.3) Trois inventions à la base du Web

- Le développement du Web est en grande partie dû à la mise en place d'un environnement client-serveur simple et accessible à tous.

5.3) Trois inventions à la base du Web

- Dans cet environnement, un client, généralement un navigateur, interagit avec un serveur par l'intermédiaire d'une interface graphique simple.

5.3) Trois inventions à la base du Web

- Un serveur communique ensuite avec un client de manière asynchrone via le protocole HTTP qui permet de transporter différents types d'informations
 - textes,
 - images,
 - des fichiers audio et
 - vidéo
- codées dans le langage à balises, HTML.

5.3) Trois inventions à la base du Web

- Dans cette section nous allons présenter les trois inventions discutées en introduction, et qui dans cet environnement client-serveur, ont permis l'évolution rapide du Web.

5.3) Trois inventions à la base du Web

– Langage HTML

- Le langage HTML, ou HyperText Markup Language, est le principal langage à balises utilisé pour afficher des pages Web et d'autres informations fournies par un serveur dans un navigateur.

```

<html>
<head>
  <title>Moteurs de recherche</title>
</head>
<body>
  <div>Liens vers deux moteurs de recherches usuels du web</div>
  <ul class="navlist">
    <li><a href="http://www.google.com">Google</a>
    <li><a href="http://www.bing.com">Bing</a>
  </ul>
  <div>Les logos de ces moteurs sont :</div>
  <table border="1">
    <tr>
      <td></td>
      <td></td>
    </tr>
  </table>
</body>
</html>

```

Affichage





Figure 16 – Exemple d'un document HTML (en haut à gauche), de sa structure interne (à droite) et de la page interprétée et affichée par un navigateur (en bas à gauche). Dans la structure du document, la portée de chaque élément est montrée par la couleur du rectangle le contenant.

5.3) Trois inventions à la base du Web

- – le terme Hypertext dans HTML, fait référence à la manière dont les pages Web sont reliées entre elles sur la Toile ;
- – le terme Markup Language définit comment les documents sont formés.

5.3) Trois inventions à la base du Web

- Ce langage permet ainsi de concevoir des documents structurés en désignant la structure des textes avec des balises, ou tags entre crochets, qui sont interprétées par un navigateur, mais non affichées dans l'interface de ce dernier.

5.3) Trois inventions à la base du Web

- De façon plus spécifique, un document HTML commence et se termine avec des balises **<html>** et **</html>**.
- Ces balises indiquent à un navigateur que l'ensemble d'un document donné est écrit suivant le standard HTML.

5.3) Trois inventions à la base du Web

- À l'intérieur de ces deux balises, le document est divisé en deux parties :
- – La première partie, ou l'en-tête, est délimitée par des balises **<head> ... </head>** et contient des informations générales comme le titre du document, l'auteur de l'information, etc. qui ne sont pas affichées par un navigateur.
- – La seconde partie, délimitée par les balises **<body> ... </body>**, contient le corps réel de ce document qui sera visible aux utilisateurs.

5.3) Trois inventions à la base du Web

- – La seconde partie, délimitée par les balises **<body> ... </body>**, contient le corps réel de ce document qui sera visible aux utilisateurs.

5.3) Trois inventions à la base du Web

- Les balises HTML sont toutes désignées par des noms.
- Les plus courantes viennent en paires, bien que certains tags connus comme des éléments vides ne sont pas appariés.

5.3) Trois inventions à la base du Web

- La première balise dans une paire est la balise ouvrante et la seconde est appelée balise fermante.
- Entre ces balises, on met généralement du texte, des tags, des commentaires ou d'autres types de contenu textuel.
- Selon les standards HTML, les noms des balises ne sont pas sensibles à la casse et une propriété commune à tous les navigateurs est que les éléments mal orthographiés, ou dont le nom n'existe pas dans l'ensemble des noms des éléments existants, sont ignorés.
- Il n'y aura donc pas d'erreurs d'affichage (en générale).

5.3) Trois inventions à la base du Web

- Hormis les noms, les attributs constituent l'autre partie importante des balises HTML.
- Un attribut est utilisé pour définir les caractéristiques d'un élément et il est placé à l'intérieur de la balise ouvrante de cet élément.
- Tous les attributs sont constitués de deux parties :
 - le nom de la propriété associée à un élément qu'on souhaite utiliser ;
 - la valeur de cette propriété.

5.3) Trois inventions à la base du Web

- Par exemple si on souhaite que les textes d'une page soient de couleur bleu et écrits avec la police Arial, on place ces textes entre les balises ** ... ** en spécifiant les propriétés recherchées dans la balise ouvrante, par exemple ****.

5.3) Trois inventions à la base du Web

- Dans la version 4 de HTML, 91 éléments déclarés sont classés soit au niveau bloc, soit au niveau texte :
- – Les éléments de niveau bloc sont des super-structures qui contiennent d'autres blocs et éléments de niveau texte. Ils sont généralement séparés des autres blocs par des marges verticales.
- – Les éléments de niveau texte représentent des textes relativement courts et ne peuvent contenir que d'autres éléments de niveau texte.

5.3) Trois inventions à la base du Web

- Parmi tous les éléments HTML, l'élément hyperlien joue un rôle central. En effet, cet élément permet de pointer la page Web contenant la balise ** ... **, vers la page dont l'adresse est spécifiée entre les guillemets de la balise ouvrante de cet élément.

5.3) Trois inventions à la base du Web

- Entre les deux balises ouvrante et fermante, il y a aussi une zone soulignée, appelée zone d'ancrage, qui permet d'inclure du texte ou de l'image et qui définit le lien ainsi créée dans le document HTML initial.

5.3) Trois inventions à la base du Web

- Dans la version 5 de HTML, il a été inclus une couche application avec de nombreuses interfaces de programmation (ou Application Programming Interface - API) et un algorithme de transfert conçu pour traiter les documents de la Toile à la syntaxe non conforme. La figure 16 montre l'exemple d'un document HTML ainsi que sa structure interne et la page interprétée et affichée par un navigateur.

```

<html>
<head>
  <title>Moteurs de recherche</title>
</head>
<body>
  <div>Liens vers deux moteurs de recherches usuels du web</div>
  <ul class="navlist">
    <li><a href="http://www.google.com">Google</a>
    <li><a href="http://www.bing.com">Bing</a>
  </ul>
  <div>Les logos de ces moteurs sont :</div>
  <table border="1">
    <tr>
      <td></td>
      <td></td>
    </tr>
  </table>
</body>
</html>

```

Affichage





Figure 16 – Exemple d'un document HTML (en haut à gauche), de sa structure interne (à droite) et de la page interprétée et affichée par un navigateur (en bas à gauche). Dans la structure du document, la portée de chaque élément est montrée par la couleur du rectangle le contenant.

5.3) *Trois inventions à la base du Web*

– Protocole de transfert hypertexte et adresses Web

- Le protocole HTTP est un protocole de couche application conçu dans le cadre de la suite des protocoles Internet et sa définition suppose un protocole de couche transport sous-jacent et fiable, comme par exemple le protocole TCP (*Transmission Control Protocol*).
- Cependant, HTTP peut utiliser des protocoles non fiables, comme le protocole UDP (*User Datagram Protocol*), pour certains services spécifiques.

5.3) *Trois inventions à la base du Web*

– Protocole de transfert hypertexte et adresses Web

- Les ressources HTTP sont identifiées et localisées sur la Toile par des adresses ou des localisateurs uniformes de ressource (*Uniform Resource Locators* - URL en anglais) comme,
- par exemple, <http://www.liglab.fr/>.
- Dans cet exemple, le terme http fait référence au protocole de transfert de données, et www.liglab.fr/ est le nom d'un domaine qui correspond à la racine d'une hiérarchie de pages Web.
- Des URL et des hyperliens dans les documents HTML forment alors un réseau de pages hypertextes reliées entre elles.

5.3) *Trois inventions à la base du Web*

– Protocole de transfert hypertexte et adresses Web

- Ce réseau peut être vu comme un graphe dirigé dans lequel un nœud représente une page Web et un arc dirigé correspond à un hyperlien entre la page source et la page dont l'adresse est indiquée dans la balise hyperlien de la première.
- Le nom de *Toile* ou Web fait référence à cette structure de graphe. La figure 17 montre le sous-graphe d'interconnexions de 659 388 pages du Wikipédia.

5.3) Trois inventions à la base du Web

– Protocole de transfert hypertexte et adresses Web

- Les hyperliens pointant vers une page sont appelés des *liens entrants* et ceux qui pointent vers d'autres pages sont des *liens sortants*.
- Il a été montré que loin d'être distribuées de façon aléatoire, ces deux types de liens suivent, sur l'ensemble des pages Web, soit une loi log-normale, soit une loi de puissance.
- Nous verrons dans la suite (dans la section 5.4) comment liens entrants et sortants sont pris en compte dans les moteurs de recherche actuels pour l'assignation de scores aux pages.

•

5.3) Trois inventions à la base du Web

– Collecte et indexation des pages sur la Toile

- Dans cette section, nous allons présenter le fonctionnement d'un robot d'indexation qui collecte les pages sur le Web, ainsi que les stratégies permettant de les indexer.

5.3) Trois inventions à la base du Web

– Collecte et indexation des pages sur la Toile

» Robot d'indexation

- Suivant le protocole HTTP, un robot d'indexation récupère les pages Web qui sont entreposées dans une liste d'adresses URL dont le robot dispose au préalable.
- Ces pages sont analysées pour en extraire les textes et les liens qu'elles contiennent.
- Ces textes extraits sont alors indexés et ces liens passent par une série de tests afin de déterminer s'ils doivent être ajoutés à la liste d'URL de départ ou non.

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation

- Au fur et à mesure que les pages sont indexées, les adresses URL correspondantes sont supprimées de cette liste.
- Les robots effectuent généralement un certain type de normalisation sur les adresses URL afin d'éviter de considérer la même ressource plus d'une fois.

5.3) Trois inventions à la base du Web

— Collecte et indexation des pages sur la Toile

» Robot d'indexation

- Il existe plusieurs types de normalisation dont les plus simples sont la conversion des URL en minuscules et la suppression des « . » et « .. ».
- De façon générale, le comportement d'un robot est régi suivant quatre principes qui sont présentés dans la suite.




Figure 17 – Graphe représentatif de 659 388 pages du Wikipédia. [Massih-Reza 2013]

5.3) *Trois inventions à la base du Web*

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation

- **Principe de sélection**
- Compte tenu du grand nombre de données disponibles sur la Toile et de leur accroissement constant,
- il est en fait impossible d'en indexer la totalité.
- Bien que la proportion indexée de la Toile par les moteurs de recherche conventionnels soit passée de 16% en 1999 à plus de 40% en 2005, ([Massih-Reza 2013])
- nous sommes encore loin d'une indexation complète du Web.
-

5.3) *Trois inventions à la base du Web*

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation

- Principe de sélection
- Comme on ne peut collecter qu'une **fraction des pages existantes**,
- il est **souhaitable** que celle-ci ne soit pas seulement un échantillon aléatoire tiré de la Toile,
- mais qu'elle contienne effectivement des pages pouvant répondre à un maximum de **besoins d'utilisateurs quelconques**.
-

5.3) *Trois inventions à la base du Web*

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation

- **Principe de sélection**
- Le principe de sélection, préconisé par la plupart des robots d'indexation actuels,
- consiste à considérer les pages à collecter
 - non seulement par rapport à leurs contenus
 - mais aussi par rapport à d'autres paramètres spécifiques à la structure de la Toile,
- notamment la popularité des pages en terme
 - des liens qu'elles contiennent,
 - de leur nombre de visites et même
 - du domaine de leur URL.
 -

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- Un robot d'indexation doit être capable de prendre en compte la nature dynamique de la Toile.
- La collecte d'information, ne serait-ce que sur une petite fraction de la Toile, peut prendre des semaines, voire des mois.

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- Au moment où un robot termine son analyse, de nombreux événements se sont produits :
 - créations,
 - mises à jour et
 - suppressions de pages.
- Du point de vue d'un moteur de recherche, la non-détection d'un événement, comme le fait de disposer d'une copie périmée d'une ressource, a un **coût associé**.
- Les fonctions de coût les plus utilisées pour le principe de revisite sont la **fraîcheur** et **l'âge**.
-

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- ***La fraîcheur***
- Notée ϕ , la fraîcheur est une mesure binaire qui indique si la copie locale d'une page au temps τ est exacte ou non. Elle est définie par :

$$\phi(p, \tau) = \begin{cases} 1 & \text{si } p \text{ est à sa copie locale au temps } \tau \\ 0 & \text{sinon} \end{cases}$$

-

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- **L'âge**
- Noté Γ , l'âge indique depuis combien de temps la copie locale d'une page p au temps
- τ est obsolète. Il est défini par :
- $\Gamma(p, \tau) = \begin{cases} 0 & \text{si } p \text{ n'est pas modifiée au temps } \tau \\ \tau - \tau' & \text{sinon} \end{cases}$
- Où τ' désigne la dernière date de modification de la page p .

5.3) *Trois inventions à la base du Web*

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- *L'âge*
- L'objectif recherché par un robot est alors soit
 - d'obtenir une fraîcheur moyenne la plus haute possible sur l'ensemble des pages associées aux URL de sa liste,
 - soit de maintenir l'âge moyen le plus bas possible pour ces pages.

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection

Principe de revisite

- **L'âge**
- Si l'on considère la **fonction de coût ϕ** , il a été montré que le principe de **revisite optimal** est celui qui consiste à garder une fraîcheur moyenne haute tout en ignorant les pages qui sont modifiées sans cesse.
- Avec la **fonction de coût Γ** , le principe de **revisite optimal** est celui qui considère les pages dont la fréquence d'accès croît de façon monotone en fonction de l'âge.
-

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection
 - Principe de revisite

Principe de politesse

- L'utilisation des robots d'indexation a un impact non négligeable sur la surcharge des serveurs, surtout si la fréquence d'accès aux serveurs pour télécharger des pages est trop élevée.
- Les robots qui demandent trop de bande passante au cours d'une longue période de temps peuvent même causer des pannes serveur.
- Les solutions envisagées pour réduire la charge des serveurs, connues sous le nom du **principe de politesse**.

5.3) Trois inventions à la base du Web

- Collecte et indexation des pages sur la Toile
 - » Robot d'indexation
 - Principe de sélection
 - Principe de revisite

Principe de politesse

- **Le principe de politesse**, comprend :
 - L'utilisation d'un fichier d'exclusion (appelé *robots.txt*) qui indique aux robots les parties des sites Web à ne pas explorer. Ce fichier contient des instructions dans un format spécifique et il se trouve sur la racine de la hiérarchie de ces sites (Par exemple <http://www.liglab.fr/robots.txt>) .
 - La restriction d'accès aux serveurs à des intervalles de demandes fixés.

5.3) Trois inventions à la base du Web

User-agent: * Allow:	Cet exemple spécifie la collecte de toutes les pages situées sur les feuilles de la racine :
User-agent: * Disallow: /	Cet exemple indique aux robots de ne collecter aucune des pages situées sur les feuilles de la racine :
User-agent: * Disallow: /tmp/ Disallow: /private/	Cet exemple indique aux robots de ne pas collecter les pages qui se trouvent sur les nœuds /tmp/ et /private/ du site :

Tableau. 5– Quelques exemples d'instructions à placer dans le fichier robots.txt pour indiquer aux robots d'indexation les parties d'un site à explorer ou à éviter lors de leurs collectes de pages.

5.3) Trois inventions à la base du Web

– Collecte et indexation des pages sur la Toile

» Robot d'indexation

- [Principe de sélection](#)
- [Principe de revisite](#)
- [Principe de politesse](#)

Principe de parallélisations

- Afin de maximiser le taux de téléchargement des pages tout en évitant les téléchargements répétitifs des mêmes pages, le principe de parallélisations consiste à lancer plusieurs processus en parallèle tout en étiquetant les URL traitées par certains processus afin d'éviter que d'autres processus les reconsidèrent à nouveau.
- Parmi les nombreux robots d'indexation existants, on peut nommer les robots *open source* suivants :
 - – GNU Wget (<http://www.gnu.org/software/wget/>) ;
 - – HTTrack (<http://www.httrack.com/>) ;
 - – Nutch (<http://nutch.apache.org/>) ;
 - – PHPCrawl (<http://phpcrawl.cuab.de/>).
 -

5.3) Trois inventions à la base du Web

Index distribués

- Une fois les pages collectées, différents index seront construits à différents endroits de la Toile.
- Nous avons vu à l'unité 2, comment fusionner les index répartis de façon distribuée pour n'en former qu'un seul qui sera utilisé pour la recherche.
- De par la nature dynamique de la construction des index sur une grande grappe de serveurs, il n'est pas possible de fusionner périodiquement ces derniers pour la recherche sur la Toile.

5.3) Trois inventions à la base du Web

» Index distribués

Index de termes

- Suivant cette stratégie, les termes du vocabulaire général de la Toile sont partitionnés suivant différents sous-ensembles.
- Chaque sous-ensemble de termes avec leurs listes de documents complètes associées est gardé sur un nœud de la Toile.
- En pratique, ce choix s'est avéré **peu performant** surtout lorsque la recherche porte sur une **requête contenant plusieurs termes**.
- Dans ce cas, la fusion finale des différents index correspondant aux différents termes de la requête nécessite l'envoi de très grandes listes de documents à travers le réseau, ce qui entraîne souvent un problème de surcharge et de congestion.
-

5.3) *Trois inventions à la base du Web*

- » Index distribués
 - Index de termes

Index de documents

- Le choix de créer des index relatifs aux partitions des pages collectées est plus commun.
- Dans ce cas, chaque nœud contient l'index d'un sous-ensemble de pages ;
- les requêtes sont ensuite envoyées sur l'ensemble des nœuds et
- les listes triées des pages sont alors fusionnées pour former le résultat final.
- La difficulté, avec cette stratégie, est que les associés à ce nœud, doivent être estimées sur l'ensemble des pages collectées avec les statistiques globales, comme idf, utilisées sur chaque nœuds pour l'ordonnancement des documents.

5.3) *Trois inventions à la base du Web*

- » Index distribués
 - Index de termes

Index de documents

- Une solution généralement admise est d'utiliser des processus en tâche de fond qui estiment ses statistiques de façon périodique et les mettent à jour sur l'ensemble des nœuds.
- Dans la suite nous allons présenter deux stratégies de recherche proposées récemment pour le calcul de scores entre une requête et les documents de la Toile.
- La spécificité de ces stratégies par rapport aux stratégies de recherche exposées dans la section précédente, est qu'elles prennent en compte l'information des liens dans les pages et utilisent des techniques issues de l'apprentissage statistique pour apprendre ces scores.

Nouvelles stratégies de recherche

- La plupart des moteurs de recherche actuels utilisent **une approche à deux étapes** pour ordonner les pages de la Toile par rapport à une requête utilisateur donnée.
- **Dans la première étape**, l'information contenue dans les pages est utilisée pour calculer des scores de similarité entre ces pages et la requête.
- De nouveaux scores sont ensuite calculés, dans **une deuxième étape**, en utilisant l'information additionnelle des liens entre pages.
- Ces scores, combinés aux scores précédents, fournissent les scores finaux par rapport auxquels les pages sont ordonnées.

Nouvelles stratégies de recherche

- Dans la suite, nous allons présenter **deux nouvelles approches** pour le calcul de scores entre une requête et des documents et l'ordonnancement des pages en utilisant l'information des liens entre pages.

» Nouvelles stratégies de recherche

Modèle d'apprentissage automatique pour la RI

- Les systèmes de recherche actuels calculent, pour une requête donnée, **quelques centaines de fonctions de score** de base entre cette requête et chaque document d'une collection et combinent ces scores avant d'assigner un score final à chacun des documents.
- La **détermination manuelle des poids** de la combinaison est très **difficile** et elle aboutit souvent à des fonctions de score **peu performantes**.
- C'est pourquoi il y a depuis quelques années un engouement particulier autour d'un nouveau cadre d'étude qui s'est fixé comme objectif **d'apprendre automatiquement** une combinaison optimale de ces fonctions de score.




Figure 18 – Schématisation de la procédure d'apprentissage d'une fonction de score f sur une base d'entraînement constituée de trois requêtes $\{q_1, q_2, q_3\}$ ainsi que des jugements de pertinence associés sur une collection de documents C donnée (figure tirée de (Usunier 2006)).

» Nouvelles stratégies de recherche

Modèle d'apprentissage automatique pour la RI

- Différentes techniques d'optimisation peuvent être utilisées pour minimiser l'erreur empirique ci-dessus, la plus connue étant la **minimisation par la descente de gradient** illustrée dans l'algorithme 5.

•

ALGORITHME 5. Algorithme de descente du gradient pour l'ordonnancement

Entrée :

- une base d'apprentissage constituée d'un ensemble de documents C ;
- un ensemble de requêtes $(q_i)_{i=1}^m$ avec jugements de pertinence $(y^i)_{i=1}^m$;

Initialisation :

- calculer P fonctions de scores $(s_k(d_j^i, q_i))$, $1 \leq k \leq P$, $1 \leq i \leq m$, $d_j^i \in \mathcal{A}_{q_i}$;
- initialiser aléatoirement les poids $\mathbf{A} = (\alpha_k)_{k=1}^P$ (équation 4.1) et calculer $\mathcal{E}^{(0)}$ (équation 4.2) ;
- initialiser le pas de gradient $\eta \in \mathbb{R}_+^*$ et la précision $\epsilon \in \mathbb{R}_+^*$ et poser $t \leftarrow 0$.

répéter

pour $k \in \{1, \dots, P\}$ faire

$\alpha_k \leftarrow \alpha_k - \eta \frac{\partial \mathcal{E}^{(t)}}{\partial \alpha_k}$

fin

$t \leftarrow t + 1$

jusqu'à ce que $|\mathcal{E}^{(t+1)} - \mathcal{E}^{(t)}| \leq \epsilon$;

Sortie : les poids de combinaison $\mathbf{A}$.

» Nouvelles stratégies de recherche

Modèle d'apprentissage automatique pour la RI

- Pour une base d'entraînement constituée de m requêtes $(q_i)_{i=1}^m$ et des jugements de pertinence associés, $(y^i)_{i=1}^m$, on calcule tout d'abord P fonctions de score $\left(s_k(d_j^i, q_i) \right)_{k=1}^p$ pour toutes les requêtes q_i de la base et leurs documents associés A_{qi} .
- Pour un pas de gradient η et une précision donnés, l'algorithme 5 met à jour les poids courants en progressant dans le sens inverse du gradient de la fonction de coût 4 avec le pas η .

•

» Nouvelles stratégies de recherche

Modèle d'apprentissage automatique pour la RI

- Cette étape de mise à jour est répétée jusqu'à ce que la différence en valeur absolue de la fonction de coût d'une itération à l'autre soit inférieure à la précision ε recherchée.
- L'utilisation de l'algorithme 5 repose sur le fait que la fonction de coût d'ordonnement considérée est dérivable en tout point.
- On remarque aussi qu'une des difficultés d'utiliser les techniques d'apprentissage est la création des bases étiquetées qui pour un ensemble de requêtes nécessitent le recueil des documents pertinents et non pertinents pour chacune des requêtes de cet ensemble.

» Nouvelles stratégies de recherche

Modèle d'apprentissage automatique pour la RI

- Certains travaux se sont intéressés à apprendre des fonctions d'ordonnancement sur des bases d'entraînement comportant un ensemble restreint de requêtes pour lesquelles on dispose des jugements de pertinence et un large ensemble de requêtes non étiquetées (Amini *et al.* 2008).
- Beaucoup d'autres travaux se sont aussi intéressés à l'étude formelle du cadre d'apprentissage de fonctions d'ordonnancement (Usunier 2006) et ont pu montrer notamment le lien qui existe entre ce dernier et le cadre de la catégorisation automatique.
-

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- **PageRank (Brin et Page 1998)** est l'approche d'ordonnancement fondé sur l'information des liens la plus populaire.
- L'algorithme de *PageRank* est notamment utilisé par le moteur de recherche Google.

•

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- Il a été inventé par **Sergey Brin et Lawrence Rank**,
- co-fondateur de la société **Google**, et
- utilise la structure des **hyperliens de la Toile**
- pour construire une chaîne de **Markov** avec une matrice de transition **P** dont le but est de
- donner la **probabilité qu'un utilisateur**, suivant de façon aléatoire les liens des pages Web sur lesquelles il navigue, **arrive sur une page particulière**.
-

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- Les nœuds de ce graphe illustrent les pages et les arcs dirigés représentent les liens entre ces pages.
- Le modèle de Markov représente alors ce graphe comme une matrice carrée **P** où un élément π_{ij} est la probabilité de transition de la page i vers la page j .
- L'hypothèse de base permettant de construire la matrice **P** est qu'un utilisateur, se trouvant sur n'importe quelle page de la Toile, clique de façon équiprobable sur les liens sortant de cette page pour arriver à une autre page.
- Ce qui, par exemple la matrice suivante:
-

$$\mathbf{P} = \begin{matrix} & \begin{matrix} p_1 & p_2 & p_3 & p_4 & p_5 & p_6 \end{matrix} \\ \begin{matrix} p_1 \\ p_2 \\ p_3 \\ p_4 \\ p_5 \\ p_6 \end{matrix} & \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{3} & 0 & 0 & \frac{1}{3} & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} \\ 0 & 0 & 0 & \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \end{matrix}$$

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

–PageRank

- Par définition le **PageRank** d'une page j , noté par **$PR(j)$** est la somme des PageRanks normalisés de toutes les pages pointant vers cette page.
- Le **PageRank normalisé** d'une page est obtenu en divisant son PageRank par le nombre de liens sortant de cette page.




Figure 19 – Un graphe dirigé représentant 6 pages Web ainsi que leurs liens et composé de deux sous-graphes gauche (nœuds p_1 , p_2 et p_3) et droite (nœuds p_4 , p_5 et p_6).

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

–PageRank

- Ainsi en notant par
- $R = (PR(1), \dots, PR(N))$
- le vecteur ligne dont la composante $j \in \{1, \dots, N\}$ correspond au *PageRank* de la page j , le calcul matriciel récursif des *PageRanks* est :
- $R = RP \quad (5.3)$

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- En initialisant le vecteur $\mathbf{R}$ par le vecteur ligne où toutes les composantes sont égales à $\frac{1}{N}$, i.e. $\mathbf{R}^{(0)} = \left(\frac{1}{N}, \dots, \frac{1}{N}\right)$, les *PageRanks* peuvent alors être estimés de manière itérative : à chaque itération l , le nouveau vecteur $\mathbf{R}^{(l+1)}$ se calcule simplement comme $\mathbf{R}^{(l+1)} = \mathbf{R}^{(l)}\mathbf{P}$.
- Il n'y a toutefois pas de garantie *a priori* que la règle de calcul itérative précédente converge vers une solution unique.
- Pour garantir cette convergence, on se repose sur des matrices ergodiques, ce qui en pratique est obtenu en construisant $\mathbf{P}$ comme ci-dessous.

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

—PageRank

- La construction de la matrice **P** a lieu à partir de la matrice d'adjacence **A** du graphe :
- $A_{ij} = 1$ s'il existe un lien de la page i vers la page j , et 0 sinon.
- Pour chaque page i contenant des liens sortants, la probabilité d'emprunter un lien conduisant à la page j peut être définie par : $\frac{A_{ij}}{\sum_{j=1}^N A_{ij}}$.

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- Les pages qui n'ont pas de liens sortants sont souvent appelées **impasses** (ou *trous noirs* lorsqu'elles comportent un grand nombre de liens entrant).
- On ne peut *a priori* pas passer d'une de ces pages à une autre page.
- Pour permettre ce passage, et pour obtenir un processus de navigation plus réaliste, on introduit un processus de *télétransportation* qui permet d'aller d'une page quelconque à n'importe quelle page du Web.
- Dans un processus de navigation, à partir d'une page donnée, on peut donc soit se *télétransporter* vers n'importe quelle autre page du Web, soit emprunter un des liens sortant de la page.

ALGORITHME 6. Algorithme de PageRank

Entrée :

- la matrice d'adjacence $\mathbf{A}$ du graphe dirigé de la Toile à un instant donné ;
- facteur d'amortissement λ ; // habituellement fixé à 0,85
- précision ϵ pour le critère d'arrêt ;

Initialisation :

- calculer la matrice de probabilité $\mathbf{P}$ par l'équation 4.4 ;
- vecteur PageRank $\mathbf{R}^{(0)} = \left(\frac{1}{N}, \dots, \frac{1}{N}\right)$;
- $l \leftarrow 0$.

répéter

$$\left| \begin{array}{l} \mathbf{R}^{(l+1)} = \mathbf{R}^{(l)} \mathbf{P}; \\ l \leftarrow l+1 \end{array} \right.$$

jusqu'à ce que $\|\mathbf{R}^{(l+1)} - \mathbf{R}^{(l)}\| \leq \epsilon$;

Sortie : vecteur PageRank $\mathbf{R}^{(l)}$.

» Nouvelles stratégies de recherche

- Modèle d'apprentissage automatique pour la RI

– PageRank

- La matrice de probabilité P qui rend compte de ce processus est alors une combinaison de ces deux types de passage :

$$P_{i,j} \begin{cases} \lambda \frac{A_{ij}}{\sum_{j=1}^N A_{ij}} + (1 - \lambda) \frac{1}{N} \text{ si } \sum_{j=1}^N A_{ij} \neq 0 \\ \frac{1}{N} \text{ sinon} \end{cases} \quad (4.4)$$

- L'algorithme 6 récapitule l'estimation itérative du vecteur des PageRanks R.
- Une preuve de la convergence de la règle itérative précédente avec la matrice P définie comme ci-dessus peut être trouvée dans (Langville et Meyer 2004).
- λ ($\lambda \in]0, 1[$) est un *facteur d'amortissement* généralement fixé à 0,85.
- Avec les premiers tests effectués sur 80 millions de pages, cet algorithme convergeait vers le vecteur solution après 25 itérations et au bout de 5 heures de calcul sur une machine Athlon 1 533 MHz.

