

DICTIONNAIRE INITIAL POUR LE PREMIER DOCUMENT.

Parle, ralentissement, croissance, récession, véritable, France, Insee, PIB, diminuer, 0,8 points, niveau, ensemble, pays, industrialisés, première, 1945, année, économies, Sud, continuer, croître, façon, ralentie,

DICTIONNAIRE INITIAL POUR LE DEUXIEME DOCUMENT.

Devant, mauvais, chiffres, croissance, gouvernement, mesure, signifie, dizaines, millions, Français, terme, difficultés, vivre, récession, ralentie, refuse, engager, plan, relance, économie, prendre, déficits, publics, réduisant, dépenses, gouffre, financiers, sommes, débloquées,

ANTI-DICTIONNAIRE POUR LES DEUX DOCUMENTS

On, ne, plus, de, la, mais, En, selon, l', le va, Il, est, même, au, des, pour, fois, depuis, leurs, diminueront, sur, toute, une, Quant, du, Sud, si, elles, vont, à, c', façon, ces, pas, ce, que, cela, disent, ils, d', un, et, veut, s', aux, les, sont,

REDUCTION DU DICTIONNAIRE GLOBAL

Parle, ralentissement, croissance, récession, véritable, France, Insee, PIB, diminuer, points, niveau, ensemble, pays, industrialisés, première, année, économies, Sud, continuer, croître, ralentie, Devant, mauvais, chiffres, gouvernement, mesure, signifie, dizaines, millions, Français, terme, difficultés, vivre, refuse, engager, plan, relance, économie, prendre, déficits, publics, réduisant, dépenses, gouffre, financiers, sommes, débloquées,

PROPORTIONS DE LA REDUCTION

Proportions de la réduction = $(100 - (47 * 100) / 103) = 54,36\%$

LES CONSEQUENCES D'UNE LEMMATISATION DES MOTS DU VOCABULAIRE

Réduction de la complexité du vocabulaire : La lemmatisation peut aider à réduire la complexité du vocabulaire en remplaçant les formes fléchies des mots (comme "manger", "mangeais", "mangé", etc.) par leur forme de base (ici, "manger").

Amélioration de la précision : La lemmatisation peut aider à améliorer la précision en réduisant le nombre de mots différents qui sont considérés comme distincts, mais qui sont en réalité des variantes d'un même mot. Par exemple, "courir", "courait", "courant" et "couru" peuvent tous être lemmatisés en "courir".

Normalisation des données : La lemmatisation peut aider à normaliser les données en garantissant que les différentes formes d'un mot sont traitées de manière cohérente, ce qui peut être important dans les applications de traitement du langage naturel.

Réduction de la taille des données : La lemmatisation peut également aider à réduire la taille des données en éliminant les formes fléchies des mots, ce qui peut être important dans les applications où l'espace de stockage est limité.

Amélioration de la vitesse de traitement : La lemmatisation peut également aider à améliorer la vitesse de traitement en réduisant le nombre de mots différents à traiter, ce qui peut être important dans les applications où le temps de traitement est critique.

Document 1 :

Ralentissement : ralentir

Croissance : croître

Récession : récession

PIB : PIB

Diminuer : diminuer

Pays : pays

Industrialisés : industrialisé

Croître : croître

Ralentie : ralentir

Document 2 :

Chiffres : chiffre

Croissance : croître

Gouvernement : gouvernement

Mesure : mesurer

Français : français

Terme : terme

Difficultés : difficulté

Récession : récession

Ralentie : ralentir

Refuse : refuser

Plan : plan

Relance : relance

Économie : économie

Déficits : déficit

Publics : public

Réduisant : réduire

Dépenses : dépense

Financiers : financier

Sommes : somme

Débloquées : débloquent

Document 1 :

Après élimination des mots vides et lemmatisation, le document 1 se réduit à :

Ralentissement

Croissance

Récession

PIB

Diminuer

Pays

Industrialisé

Croître

Ralentir

La taille du vocabulaire pour le document 1 est donc de 9 mots.

Document 2 :

Après élimination des mots vides et lemmatisation, le document 2 se réduit à :

Chiffre

Croissance

Gouvernement

Mesurer

Français

Terme

Difficulté

Récession

Ralentir

Refuser

Plan

Relance

Économie

Déficit

Public

Réduire

Dépense

Financier

Somme

Débloquer

La taille du vocabulaire pour le document 2 est donc de 20 mots.

La liste inversée, également appelée index inversé ou indexation inversée, est une technique couramment utilisée en informatique pour indexer et rechercher rapidement des mots dans un grand corpus de texte. Elle consiste à créer une liste de tous les mots uniques présents dans le corpus, avec pour chaque mot une liste des documents dans lesquels il apparaît.

Voici quelques termes présents dans les documents proposés et leur liste inversée :

Terme "croissance":

Document 1

Document 2

Terme "récession":

Document 1

Document 2

Terme "PIB":

Document 1

Terme "déficit":

Document 2

Terme "financier":

Document 2

Dans chaque cas, la liste inversée indique dans quels documents le terme en question apparaît. Par exemple, on peut voir que le terme "croissance" apparaît à la fois dans le document 1 et le document 2.